TP / Mini-projet — Prédiction des feux de forêt

Régression de la surface brûlée et variante classification

Plan

1. Contexte scientifique (FWI)
2. Données et EDA (distribution, corrélations)
3. Méthodologie (pré-traitements, split, validation)
4. Régression : résultats et discussion
5. Classification binaire : résultats et discussion
6. Bonus et conclusion

Contexte : indices FWI

Les indices **FWI (Fire Weather Index)** résument l'« ètat du combustible » et le danger de propagation :

- `FFMC` : humidité des combustibles fins (court terme)
- `DMC` : humidité couche organique (moyen terme)
- `DC` : sécheresse profonde (long terme)
- `ISI` : potentiel de propagation initiale (dépend du vent)

Objectif : prédire la surface brûlée $\texttt{area}$ (colonne `area`, en hectares) à partir de la météo et des indices FWI.

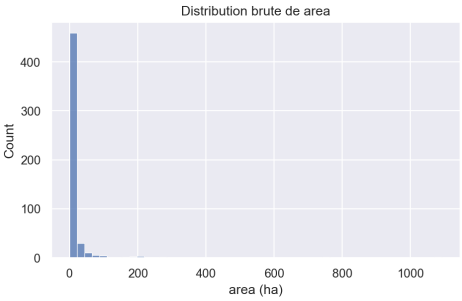
Données : Forest Fires (`forestfires.csv`)

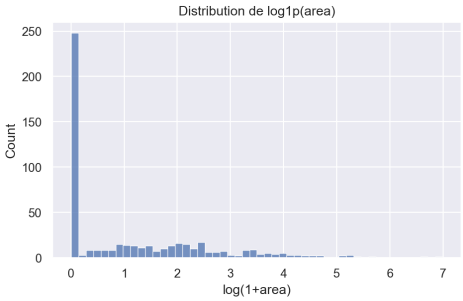
- Cible : `area`(surface brûlée `area`, en ha)
- Variables : coordonnées (`X`,`Y`), calendrier (`month`,`day`), FWI (`FFMC`,`DMC`,`DC`,`ISI`), météo (`temp`,`RH`,`wind`,`rain`)
- Particularité : beaucoup de zéros sur `area`+ quelques valeurs extrêmes

Remarque : `month` et `day` sont encodés en one-hot.

EDA : distribution de area et effet de $\log(1 + \text{area})$

- areaest très asymétrique (beaucoup de zéros)
- La transformation $\log(1 + \text{area})$ rend la cible plus exploitable pour la modélisation





Transformation de la cible

Comme la distribution est très asymétrique, on utilise :

$$y = \log(1 + \text{area})$$

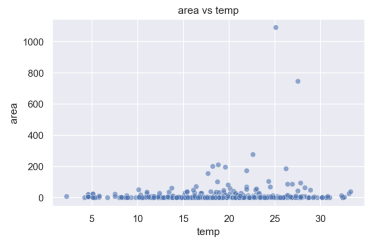
- Stabilise l'apprentissage (moins dominé par les extrêmes)
- Gère naturellement $\text{area} = 0$
- Les métriques (RMSE/MAE) sont rapportées en espace log, cohérent avec l'entraînement

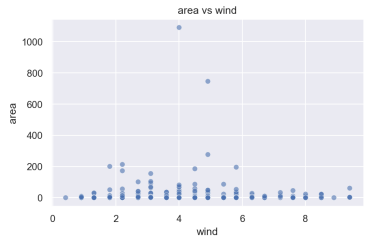
EDA : relations simples (température / vent)

- Pearson : relation linéaire (sensible aux outliers)
- Spearman : relation monotone (plus robuste)

Observation : corrélations souvent faibles (phénomène multi-factoriel et bruité).

Illustration : nuages de points exportés depuis le notebook.





Méthodologie : pré-traitements et pipeline

- Variables numériques : **standardisation** (important pour SVR/KNN)
- Variables catégorielles (`month`, `day`) : **one-hot encoding**
- Implémentation : `Pipeline` + `ColumnTransformer` (scikit-learn)

Avantage : pré-traitement inclus dans la validation et la recherche d'hyperparamètres (pas de fuite d'information).

Méthodologie : split, validation et métriques

- Split train/test : 80% / 20%
- **Validation croisée 10-fold** sur le train (robustesse)
- Régression : RMSE/MAEsur $\log(1 + \mathrm{area})$
- Classification : Accuracy + Precision/Recall/F1 (split stratifié)

Protocole expérimental (régression)

- Baseline : `DummyRegressor` (médiane)
- Modèles : Linear Regression, SVR (RBF), KNN Regressor
- Sélection d'hyperparamètres : `GridSearchCV` avec **CV=10**
- Score optimisé : `neg_root_mean_squared_error`

Régression : GridSearch (SVR / KNN)

- SVR (RBF) : recherche sur C, γ, ϵ
- KNN : recherche sur `n_neighbors`, `weights`, distance ($p = 1/2$)
- Objectif : améliorer la performance vs baseline, sans sur-apprentissage

Résultats régression (RMSE/MAEsur $\log(1 + \text{area})$)

Note : la cellule **Export Beamer** du notebook génère automatiquement ce tableau.

Modèle	RMSE (test, log)	CV 10-fold RMSE (log)
KNNRegressor(best)	1.490	1.352 ± 0.185
LinearRegression	1.517	1.509 ± 0.340
SVR(best)	1.572	1.442 ± 0.244
DummyRegressor(median)	1.643	1.519 ± 0.279

Message clé : comparer à la baseline et juger la stabilité via la CV.

Discussion régression (interprétation)

- Les modèles non-linéaires peuvent réduire le RMSE (log), mais les gains restent souvent limités
- La CV permet d'évaluer la stabilité : forte variabilité $\Rightarrow$ risque de sur-apprentissage
- Les **événements extrêmes** (grands feux) sont rares $\Rightarrow$ prédiction précise difficile

Variante classification binaire

On transforme :

- Classe 1 : $\text{area} > 0$ (un feu)
- Classe 0 : $\text{area} = 0$ (aucun feu)

- Split stratifié train/test
- Métriques : Accuracy + Precision/Recall/F1
- CV : **Stratified 10-fold** sur le train
- Modèles : Dummy, Logistic Regression, SVC (RBF), KNN

Classification : enjeu et déséquilibre

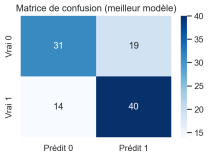
- La cible $\mathrm{area} > 0$ peut être déséquilibrée (beaucoup de zéros)
- On privilégie F1 / Precision / Recall plutôt que l'Accuracy seule
- CV : **Stratified 10-fold** sur le train

Résultats classification (test + CV 10-fold)

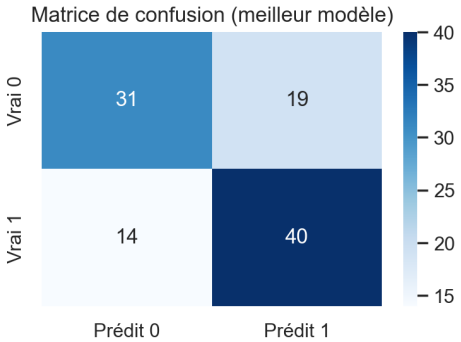
Note : la cellule **Export Beamer** génère aussi ce tableau.

Modèle	F1 (test)	CV 10-fold F1
SVC(rbf)	0.708	0.583 ± 0.052
KNNClassifier	0.689	0.618 ± 0.049
DummyClassifier(most_frequent)	0.684	0.687 ± 0.009
LogisticRegression	0.593	0.494 ± 0.050

Option : matrice de confusion exportée.



Matrice de confusion (meilleur modèle)



Lecture : compromis faux positifs / faux négatifs ⇒ choix de seuil selon l'objectif (Recall vs Precision).

Discussion classification

- Un bon F1 signifie un compromis correct entre détection (Recall) et fausses alertes (Precision)
- La matrice de confusion permet de visualiser les erreurs systématiques
- Limite : la prédiction à partir d'indices météo/FWI reste bruitée (facteurs non observés : intervention, topographie fine, etc.)

Bonus : sélection de variables (top-4)

Approche (dans le notebook) : **Permutation Importance** sur un split interne du train.

- Objectif : garder seulement 4 variables pertinentes
- Ré-entraîner un modèle simple (ex : Linear Regression) avec ces variables

Top-4 variables (Permutation Importance) : `DC`, `month`, `DMC`, `temp`
RMSE (hectares) : LinearRegression(raw)=107.767 ; LinearRegression(log→area)=109.799.

Bonus : avec vs sans transformation log

Comparaison à interpréter avec prudence :

- Sans log : l'erreur (en ha) est dominée par les grands feux
- Avec log : apprentissage plus stable ; reconversion $\widehat{\text{area}} = \exp(\hat{y}) - 1$ potentiellement biaisée

À compléter : RMSE en hectares pour les deux variantes (cf. cellule Bonus 2).

Conclusion

- Prédire area (colonne `area`) est difficile (beaucoup de zéros + extrêmes)
- $\log(1 + \mathrm{area})$ améliore la stabilité pour la régression
- Les modèles non-linéaires peuvent aider, mais la CV 10-fold est essentielle pour juger la robustesse
- En classification, l'Accuracy seule est insuffisante : regarder F1 + matrice de confusion

Limites / pistes : features saisonnières, ensembles, calibration/seuils (prioriser recall vs precision).

Références et reproductibilité

- Notebook d'analyse : `ForestFirePred.ipynb`
- Données : `forestfires.csv`
- Code : scikit-learn (pipelines, GridSearchCV, cross_validate)

Pour compiler : `pdflatex ForestFirePred_presentation.tex`